

Studi Perbandingan Kinerja *Support Vector Machine* Pada Klasifikasi Diabetes Mellitus Menggunakan Fitur *Regular Expression* dan *Non-Regular Expression*

Nur Wachid Adi Prasetya^{1*}, Linda Perdana Wanti², Riyadi Purwanto³

¹Program Studi Sarjana Terapan Teknologi Rekayasa Multimedia, Politeknik Negeri Cilacap

²Program Studi Sarjana Terapan Rekayasa Keamanan Siber, Politeknik Negeri Cilacap

³Program Studi Teknik Informatika, Politeknik Negeri Cilacap

^{1,2,3}Jln. Dr. Soetomo No.1 Karangcengis Sidakaya, Kabupaten Cilacap, 53212, Indonesia

E-mail: nwap.pnc@pnc.ac.id¹, linda_perdana@pnc.ac.id², riyadi_purwanto@pnc.ac.id³

Abstrak

Info Naskah:

Naskah masuk: 9 Desember 2025

Direvisi: 8 Januari 2026

Diterima: 12 Januari 2026

Diabetes mellitus merupakan penyakit tidak menular yang perkembangannya cepat dan berdampak serius pada kualitas hidup. Informasi dalam rekam medis, khususnya resep dan hasil pemeriksaan laboratorium yang berisi teks tidak terstruktur, perlu diekstraksi secara sistematis menggunakan teknik *text mining* untuk menentukan klasifikasi diabetes mellitus. Penelitian ini bertujuan membandingkan kinerja klasifikasi *Support Vector Machine* (SVM) pada data diabetes mellitus dengan dan tanpa ekstraksi fitur menggunakan *Regular Expression* (Regex). Proses dilakukan melalui tahapan praproses data, ekstraksi fitur, pembobotan TF-IDF, serta pelatihan dan evaluasi model menggunakan *confusion matrix* akurasi, presisi, *recall*, dan *F1-score*. Hasil menunjukkan bahwa kedua pendekatan menghasilkan akurasi tinggi (98,8–98,9%), namun model tanpa Regex sedikit lebih unggul pada akurasi sebesar 98,93%, dibandingkan model dengan Regex sebesar 98,83%. Kesimpulannya, SVM dapat digunakan secara efektif dalam klasifikasi data medis berbasis teks, dan penggunaan Regex memiliki potensi namun perlu dioptimalkan sesuai konteks data, karena Regex dapat mereduksi atau menyaring pola tertentu dari teks tertentu.

Abstract

Keywords:

comparative assessment;
support vector machine;
diabetes mellitus;
classification;
regular expression.

Diabetes mellitus is a rapidly progressing non-communicable disease that significantly affects quality of life. Clinical information in electronic medical records, such as prescriptions and laboratory results, often appears as unstructured text and therefore requires text-mining techniques for accurate classification. This research compares the performance of the Support Vector Machine (SVM) classifier on diabetes mellitus data processed with and without feature extraction using Regular Expressions (Regex). The workflow includes data preprocessing, feature extraction, TF-IDF weighting, model training, and evaluation using accuracy, precision, recall, and F1-score. Results show that both approaches achieve high accuracy (98.8–98.9%), with the non-Regex model performing slightly better at 98.93% compared to 98.83% for the Regex-based model. These findings indicate that SVM is effective for classifying text-based clinical data, while Regex provides potential benefits but requires further optimization to ensure its suitability for various medical text contexts.

*Penulis korespondensi:

Nur Wachid Adi Prasetya

E-mail: nwap.pnc@pnc.ac.id

1. Pendahuluan

Diabetes Mellitus termasuk bukan penyakit menular, tetapi perkembangannya sangat cepat dan dapat berdampak serius pada aktivitas serta kualitas hidup seseorang, karena itulah penyakit ini sering dianggap sebagai salah satu penyebab kematian yang perlu diwaspadai [1]. Diabetes mellitus merupakan masalah kesehatan serius yang pada 2021 diderita oleh 4,5 juta orang di Indonesia, dan diprediksi mencapai 12,4 juta pada 2025 [2], dan diperkirakan menjadi 28,6 juta penderita pada tahun 2045 mendatang [1].

Mengetahui klasifikasi diabetes mellitus sangat membantu dalam memilih penanganan yang tepat. Dengan cara ini, pasien dapat terhindar dari risiko komplikasi, kualitas hidup mereka dapat lebih baik, dan beban kerja fasilitas kesehatan pun dapat berkurang [3][4]. Salah satu cara mengetahui klasifikasi diabetes mellitus adalah dengan melihat data pemeriksaan laboratorium, terutama tingkat gula darah dan data medis lain yang tercatat dalam rekam medis pasien, serta peresepan obat pasien diabetes mellitus. Pada banyak kasus, data medis tersebut tidak hanya berupa angka terstruktur, tetapi juga berupa teks bebas seperti diagnosis dokter, keluhan, dan catatan klinis, sehingga memerlukan pendekatan *text mining* untuk diekstraksi dan diklasifikasikan secara sistematis [5][6]. Dengan bantuan *text mining*, informasi penting dari teks medis dapat dikenali dan diambil secara lebih efektif [6].

Pada ilmu komputer, *text mining* dikenal sebagai metode yang digunakan untuk menemukan dan mengekstraksi informasi tersembunyi dari data teks yang belum terstruktur. Di bidang kesehatan, sumber data ini mencakup catatan medis, laporan pemeriksaan, serta resep yang biasanya ditulis dalam bentuk teks bebas. Melalui integrasi NLP, pembelajaran mesin, dan metode statistik, teknik ini memungkinkan sistem untuk memahami konteks medis secara otomatis dan mengubah data mentah menjadi pengetahuan yang bermanfaat [7][8]. Peran penentuan keparahan penyakit sangat penting dalam diagnosa medis, dan menggabungkan data obat dengan hasil klinis mampu meningkatkan ketepatan dalam memahami kondisi pasien [9][10][11].

Beragam pendekatan telah digunakan dalam studi sebelumnya, mulai dari SVM, *Naïve Bayes*, K-NN, hingga *Decision Tree* dalam mengelola data klinis [12][13]. Pendekatan yang lebih canggih seperti LSTM, Attention Mechanism, dan Transformer-based NLP kini mulai banyak diadopsi karena kemampuannya menangkap makna dalam teks medis dan meningkatkan ketepatan analisis [14][15][16].

Studi-studi sebelumnya memperlihatkan bahwa penerapan *text mining* dalam klasifikasi penyakit memberikan hasil yang menjanjikan, termasuk dalam menganalisis gangguan neurologis [17], luka bakar [18], hingga keganasan kanker [15]. Bahkan, data resep saja dalam beberapa penelitian sudah cukup untuk melakukan deteksi penyakit dengan akurat, yang membuka ruang untuk eksplorasi lanjutan jika digabungkan dengan hasil pemeriksaan klinis [19].

Oleh karena itulah, penelitian ini mengajukan integrasi hasil pemeriksaan dan peresepan sebagai dasar klasifikasi penyakit diabetes melitus menggunakan pendekatan *text mining* dan metode klasifikasi SVM. Berbeda dari riset terdahulu yang hanya pada satu sumber, pendekatan ini berupaya membangun sistem klasifikasi penyakit diabetes mellitus, dengan menggabungkan data hasil pemeriksaan klinis dan resep obat.

Selain itu, penelitian ini membandingkan penggunaan fitur *Regular Expression* (Regex) dan tanpa Regex pada data yang diperoleh setelah tahap prapemrosesan data. Oleh karena data pemeriksaan klinis dan resep obat berupa data teks yang memiliki struktur yang tidak seragam dan banyak istilah medis, maka penelitian ini menggunakan Regex, untuk menangkap pola penting dari teks medis, seperti data obat, dosis obat, jumlah obat yang diberikan, frekuensi konsumsi obat, data pemeriksaan lab, serta hasil lab, agar data yang sebelumnya tidak rapi dapat diubah menjadi fitur yang lebih bermakna bagi model SVM [20]. Beberapa penelitian menunjukkan bahwa penggunaan Regex dapat membantu meningkatkan akurasi klasifikasi karena teknik ini mampu mengurangi noise dan membuang bagian teks yang tidak relevan [21].

2. Metode


Metode yang digunakan pada penelitian ini adalah *Support Vector Machine* (SVM). SVM merupakan salah satu metode teknik regresi atau klasifikasi yang belajar dari data sebelumnya melalui proses pelatihan tersupervisi. Dalam penerapannya, model akan memilih parameter terbaik dari sekumpulan nilai yang telah ditentukan sebelumnya, atau disebut himpunan kandidat. Pendekatan ini sering digunakan dalam klasifikasi biner, yaitu ketika data harus dibedakan menjadi dua kelompok, seperti positif dan negatif [22][23].

Penelitian ini menggunakan metode SVM, karena SVM memiliki kelebihan dalam hal penerapannya di bidang kesehatan, antara lain SVM menunjukkan akurasi yang tinggi untuk klasifikasi penyakit berdasarkan data klinis lokal dibandingkan metode lain [24][25][26][27], serta SVM memiliki keunggulan untuk memproses data rekam medis elektronik, karena mampu menangani fitur yang sangat besar, seperti TF-IDF atau *word embeddings*, sehingga cukup efektif untuk membaca pola pada resep obat, catatan diagnosis, maupun riwayat konsultasi pasien [26][28][29].

Pada penelitian ini juga digunakan *Regular Expression* (Regex) untuk membandingkan ekstraksi fitur dengan atau tanpa Regex. Regex merupakan rangkaian karakter yang merepresentasikan pola pencarian dalam teks dan dapat diformalkan sebagai kumpulan string pada alfabet tertentu [30], menggunakan teknik pencocokan pola konvensional yang mudah ditafsirkan dan relevan untuk teks medis yang membutuhkan validasi oleh ahli bidang terkait [31]. Pada data medis, Regex menawarkan sejumlah kelebihan jika dibandingkan dengan pendekatan machine learning pada umumnya, antara lain tingkat interpretabilitas yang tinggi, kemampuan efektif dalam menangkap pola berurutan sehingga hubungan dan jarak antar istilah klinis dapat direpresentasikan dengan baik, ketahanan terhadap keragaman teks termasuk singkatan, kesalahan penulisan, dan variasi bahasa yang umum digunakan dalam dokumen

medis, serta efisiensi dalam kebutuhan data latih, di mana kinerja yang memadai tetap dapat dicapai meskipun jumlah data berlabel relatif terbatas [30][31].

Adapun langkah dari penelitian ini terlampir pada Gambar 1.



Gambar 1. Langkah penelitian

Berdasarkan Gambar 1, tahapan penelitian yang dilakukan adalah sebagai berikut:

1) Pengumpulan data:

Pengumpulan data dilakukan pada sumber terpercaya, yaitu rumah sakit, dengan mengambil data rekam medis, hasil diagnosa, resep obat, atau dataset publik, yang dapat berupa data terstruktur (CSV, tabel medis) atau tidak terstruktur (teks diagnosa, resep). Pengumpulan data diambil dari RSUD Banjarnegara.

2) Prapemrosesan data

Pada langkah ini, data dibersihkan dan disiapkan agar layak digunakan dalam pelatihan model. Proses ini meliputi:

- Pembersihan teks** (menghapus karakter tidak penting). Beberapa data yang didapat masih mengandung karakter seperti titik dua (:), petik dua ("), dan sebagainya. Hal ini dapat mengganggu langkah praprosesing berikutnya, seperti dapat menghambat proses selanjutnya jika kata masih mengandung tanda baca atau simbol, serta dapat menyebabkan kata yang mengandung karakter sebagai fitur penting ketika proses transformasi data, padahal sebenarnya dianggap tidak bermakna. Proses menghapus atau mengoreksi data tidak lengkap, duplikat, tidak relevan, atau salah ketik dari data medis [19].
- Case folding**, yaitu semua huruf pada teks diubah menjadi huruf kecil agar formatnya seragam. Penyeragaman ini membantu proses pembersihan data, seperti menghapus simbol atau istilah khusus yang tidak diperlukan, sehingga pengolahan teks menjadi lebih sederhana [32].
- Ekstraksi fitur** yang dilakukan adalah mengambil data obat, dosis obat, jumlah obat yang diberikan, frekuensi konsumsi obat, data pemeriksaan lab, serta hasil lab. Ekstraksi ini menggunakan *Regular Expression*

(Regex). Regex adalah cara untuk menentukan pola tertentu agar kata yang dicari dapat ditemukan dengan mudah. Dalam pemrosesan teks, teknik ini sering digunakan karena pola-pola tersebut dapat dikenali dengan cepat [20]. Adapun persamaan Regex seperti pada persamaan (1) berikut [31]:

$$R_i = P_i . (\#_ \#(N_i)) \quad (1)$$

Di mana:

- P_i : komponen positif berupa pola yang ditargetkan,
 N_i : komponen negatif yang berfungsi mengecualikan pola tertentu simbol
 $\#_ \#$: operator NOT untuk menyaring hasil yang tidak diinginkan.

- Stopword removal**, yaitu menghapus kata-kata umum yang tidak memiliki makna penting dalam konteks klasifikasi [33]. *Stopword removal* dilakukan jika tidak melakukan ekstraksi fitur dengan Regex.
- Concatenate**, yaitu menggabungkan data proses penyambungan atau penggabungan string, teks, data, atau array, baik secara horizontal maupun vertikal, untuk membentuk satu entitas yang lebih besar atau lebih lengkap, sehingga dapat diproses oleh model. Proses ini penting untuk membuat konteks penuh dari dua input, sebelum dianalisis atau diklasifikasikan oleh model [34].
- Labeling**, yaitu proses memberikan penanda (label) atau kategori tertentu pada setiap unit data, sehingga data tersebut dapat dikenali dan diproses oleh model machine learning. Dalam konteks data teks, proses labeling mengklasifikasikan setiap kalimat atau komentar menjadi kelas tertentu [35].

3) Pembobotan:

Proses ini menentukan representasi fitur untuk tahap klasifikasi selanjutnya, dengan mengubah teks menjadi representasi numerik menggunakan *Term Frequency-Inverse Document Frequency* TF-IDF). TF-IDF merupakan teknik yang digunakan untuk mengonversi kata menjadi nilai numerik dalam bentuk vektor guna menilai tingkat relevansi sebuah kata dalam dokumen atau kumpulan dokumen (korpus) [36].

Pada dasarnya, TF-IDF digunakan untuk melihat seberapa penting sebuah kata dalam sebuah teks. Caranya dimulai dengan menghitung seberapa sering kata itu muncul pada kalimat tertentu (*Term Frequency /TF*) [37][38], dengan persamaan (2) berikut:

$$TF(k_x, d_y) = f(k_x, d_y) \quad (2)$$

Di mana:

- k_x : kata ke-x
 d_y : dokumen ke-y
 $f(k_x, d_y)$: jumlah berapa kali kata k_x muncul dalam dokumen d_y

Kemudian, *Inverse Document Frequency* (IDF) digunakan untuk menilai tingkat kepentingan kata dalam keseluruhan dokumen. IDF didapatkan dengan menghitung logaritma dari jumlah total kalimat/dokumen dibagi dengan jumlah kalimat/dokumen yang memuat kata tersebut [37][38], dengan persamaan (3) berikut:

$$IDF(k_x) = \log \left(\frac{N}{d_y(k)} \right) \quad (3)$$

Di mana:

N : jumlah total dokumen
 $d_y(k)$: jumlah dokumen yang mengandung kata k

Setelah itu, kedua nilai tersebut dikalikan untuk setiap kata di setiap kalimat/dokumen, untuk menghasilkan skor yang menunjukkan seberapa besar peran kata tersebut dalam menjelaskan isi dokumen [36][37][38], menggunakan persamaan (4) seperti berikut ini:

$$TF - IDF(k_x, d_y) = TF(k_x, d_y) * IDF(k_x) \quad (4)$$

Di mana:

$TF(k_x, d_y)$: seberapa sering sebuah kata x muncul di dokumen y
 $IDF(k_x)$: seberapa penting sebuah kata x di dokumen y

4) Pembentukan dan pelatihan model:

Model klasifikasi dibentuk menggunakan algoritma SVM. Data latih digunakan untuk melatih model agar mengenali pola klasifikasi penyakit dari input data. Pada tahap ini, data yang sudah terkumpul dipisah menjadi data latih dan data uji. Pembagiannya menggunakan parameter $test_size = 0.2$, sehingga 80% data dipakai untuk melatih model, dan 20% data digunakan untuk menguji seberapa baik model bekerja [39].

Guna memisahkan data linear maupun non-linear, SVM digunakan sebagai algoritma klasifikasi yang bertujuan menemukan *hyperplane* optimal sehingga dua kelas data dapat dipisahkan dengan jelas, dan dalam prosesnya model linear diterapkan menggunakan persamaan khusus untuk memperoleh pemisah terbaik [40][41], dengan persamaan (5) berikut ini:

$$Y = w^T x_i + b, \text{ di mana } i = 1, 2, \dots, l \quad (5)$$

Di mana:

x_i : vektor baris yang panjangnya mengikuti jumlah fitur yang digunakan.
 Y : label data yang hanya bisa bernilai -1 atau +1.

l : berapa banyak data yang dipakai dalam proses pelatihan.
 w : menentukan seberapa besar setiap fitur memengaruhi hasil prediksi.
 b : nilai bias, yaitu bagian dari model yang menjelaskan adanya selisih atau kecenderungan kesalahan dalam prediksi.

Dalam SVM, margin maksimum dihitung dengan memanfaatkan *support vector*, yaitu titik-titik data yang menjadi penentu batas pemisah. Nilai margin ini kemudian diperoleh melalui persamaan (6) yang tersedia [39]:

$$(w \cdot x_i) + b = 0 \quad (6)$$

Ketika suatu data (x_i) dikategorikan sebagai kelas negatif atau -1, kondisi tersebut dijelaskan menggunakan persamaan (7) yang tercantum berikut ini [39]:

$$(w \cdot x_i + b) \leq 1, \text{ di mana } Y_i = -1 \quad (7)$$

Adapun untuk data yang termasuk kelas positif atau +1, digunakan rumus perhitungan yang berbeda, dan penjelasannya dapat dilihat pada persamaan (8) di bawah ini [39]:

$$(w \cdot x_i + b) \geq 1, \text{ di mana } Y_i = 1 \quad (8)$$

5) Evaluasi Model:

Dalam mengevaluasi model, *Confusion Matrix* digunakan untuk melihat apakah prediksi yang dihasilkan sudah tepat atau belum, kemudian dihitung akurasi, presisi (*precision*), *recall*, dan *F1-score* agar kualitas model dapat dinilai secara menyeluruh. Keempat metrik tersebut sangat bergantung pada nilai TP (*True Positive*), TN (*True Negative*), FP (*False Positive*), dan FN (*False Negative*). TP dan TN menunjukkan jumlah data yang diprediksi benar, sedangkan FP dan FN menunjukkan kesalahan model dalam membedakan kelas positif dan negatif. Dengan melihat kombinasi nilai-nilai ini, dapat diketahui sejauh apa model tersebut benar-benar mampu mengenali pola dan membuat prediksi yang akurat [39]. Persamaan (9) di bawah untuk mencari nilai akurasi, persamaan (10) mencari nilai presisi, persamaan (11) untuk mencari nilai *recall*, dan persamaan (12) untuk menilai *F1-score*.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \quad (9)$$

$$Precision = \frac{TP}{FP + TP} \quad (10)$$

$$Recall = \frac{TP}{FN + TP} \quad (11)$$

$$F1 - Score = 2 \times \frac{(Recall \times Precision)}{(Recall + Precision)} \quad (12)$$

3. Hasil dan Pembahasan


Data yang digunakan pada penelitian ini adalah seperti diperlihatkan pada Tabel 1.

Tabel 1. Sebaran data berdasarkan kelas target

KELAS_DM	
dm-1	5187
dm-2	4624
Name: count, dtype: int64	

Berdasarkan Tabel 1, terdapat dua kelas utama yang diidentifikasi, yaitu dm-1 dan dm-2. Kelas dm-1 adalah kelas penyakit diabetes mellitus kelas 1, yaitu ketika pasien mendapatkan resep obat yang termasuk insulin (*levemir*, *novorapid*, *novomix*, *humalog mix*, *ryzodeg*, *sansulin*, *ezelin*, *lantus*), atau kode pada kolom *KELAS_DM* adalah e.10. Sedangkan kelas dm-2 adalah kelas penyakit diabetes mellitus kelas 2, yaitu ketika pasien tidak mendapatkan resep obat insulin seperti kelas 1, atau kode pada kolom *KELAS_DM* adalah e.11.

Berdasarkan jumlah kemunculan, kelas dm-1 memiliki 5.187 data, sedangkan kelas dm-2 memiliki 4.624 data. Selisih antara kedua kelas ini adalah 563 data, atau sekitar 5,7% dari total data. Visualisasi pada Gambar 2 menunjukkan bahwa meskipun distribusi antar kelas tidak seimbang sempurna, ketimpangannya tergolong kecil.



Gambar 2. Visualisasi sebaran data tiap kelas target

Distribusi target seperti Gambar 2 di atas tidak termasuk dalam kategori "*imbalanced class*" yang ekstrem, sehingga pada penelitian ini tidak dilakukan proses oversampling dan undersampling, karena pada algoritma klasifikasi seperti SVM masih mampu melakukan pembelajaran yang baik tanpa penyesuaian distribusi kelas. Oleh karena itu, penggunaan teknik oversampling atau undersampling tidak diperlukan, dan justru dapat memperkenalkan bias atau noise baru ke dalam model.

Langkah pertama yang dilakukan adalah pembersihan data dan *case folding*. Langkah ini membersihkan data dari data yang kosong, dan mengubah data menjadi huruf kecil. Contoh hasil langkah ini adalah pada Tabel 2 berikut.

Tabel 2. Contoh hasil data *cleaning* dan *case folding*

RESEP	LAB	KELAS_DM
1. acarbose 100mg tab (2) (46) 2 x sehari 1 tab/kaps sebel, 2. acarbose 100mg tab (2) (14) 2 x sehari 1 tab/kaps sebel, 3. gabapentin 300mg (23) 1 x sehari 1 tab/kaps sebel, 4. gabapentin 300mg (7) 1 x sehari 1 tab/kaps sebel, 5. glimepiride 2 mg (7) 1 x sehari 1 tab/kaps sebel, 6. glimepiride 2 mg (23) 1 x sehari 1 tab/kaps sebel, 7. valsartan 160 tab (23) 1 x sehari 1 tab/kaps sebel, 8. valsartan 160 tab (7) 1 x sehari 1 tab/kaps sebel, 9. metformin 500 (1) (90) 3 x sehari 1 tab/kaps sebel, 10. paracetamol (pct) tab 500 mg (2) (15) 3 x sehari 1 tab/kaps sebel kp nyeri kepala, 11. domperidon 10mg tab (2) (15) 3 x sehari 1 tab/kaps sebel kp mual	gds=154	1. e11 non-insulin-dependent diabetes mellitus, 2. i10 essential (primary) hypertension

Tabel 3. Contoh hasil ekstraksi fitur dengan Regex

RESEP	LAB	KELAS_DM
amlodipin_10_0_1 amlodipin_10_0_1 candesartan_16_0_1 candesartan_16_0_1 ezelin-insulin_0_0_3 jarum-bd_0_0_0 novorapid-flexpen_0_0_3 novorapid-flexpen_0_0_3 paracetamol-pct-tab_500_0_2 gabapentin_100_0_1	gds_421	1. e11 non-insulin-dependent diabetes mellitus hipertensi neuropati myalgia

Tabel 4. Contoh hasil tanpa ekstraksi fitur

RESEP	LAB	KELAS_DM
1 amlodipin 10 mg 23 1 x sehari 1 tabkaps sebel 2 amlodipin 10 mg 7 1 x sehari 1 tabkaps sebel 3 candesartan 16mg tab 23 1 x sehari 1 tabkaps sebel 4 candesartan 16mg tab 7 1 x sehari 1 tabkaps sebel 5 gabapentin 300mg 23 1 x sehari 1 tabkaps sebel 6 gabapentin 300mg 7 1 x sehari 1 tabkaps sebel 7 glimepiride 2 mg 7 1 x sehari 1 tabkaps sebel 8 glimepiride 2 mg 23 1 x sehari 1 tabkaps sebel 9 metformin 500 1 90 3 x sehari 1 tabkaps sebel 10 mecobalamin 500mg 60 2 x sehari 1 tabkaps sebel	gdp214	1. e11 non-insulin-dependent diabetes mellitus hipertensi neuropati myalgia

Tabel 5. Contoh hasil penggabungan dan pelabelan pada data terekstraksi fitur

RESEP_EXAM	KELAS_DM
jarum-bd_0_0_0 lansoprazole_30_0_1 paracetamol-pct-tab_500_0_3 cetirizine-tab_0_0_1 metformin_0_0_3 furosemide_0_0_1 candesartan_8_0_1 candesartan_8_0_1 curcuma-force_0_0_3 ezelin- insulin_0_0_3 gds_256	dm-1
acarbose_100_0_2 acarbose_100_0_2 gabapentin_300_0_1 gabapentin_300_0_1 glimepiride_2_0_1 glimepiride_2_0_1 valsartan_0_0_1 valsartan_0_0_1 metformin_0_0_3 paracetamol-pct-tab_500_0_3 domperidon_10_0_3 gds_154	dm-2

Tahap selanjutnya adalah implementasi perbandingan menggunakan ekstraksi fitur dengan Regex dan tanpa menggunakan Regex. Adapun sebagai perbandingan, maka data hasil pembersihan (*cleaning*) dan *case folding* ini, akan dilakukan ekstraksi fitur dengan Regex. Penerapan Regex untuk mengambil informasi tertentu seperti nama obat, dosis obat, jumlah obat, dan frekuensi konsumsi obat pada kolom Resep. Sedangkan pada kolom Lab, diambil nama tes lab dan hasilnya. Contoh hasil langkah ini adalah pada Tabel 3. Pada data yang tidak melalui ekstraksi fitur dengan Regex, maka data tersebut akan dilanjutkan ke proses stopword removal, untuk menghilangkan kata-kata yang umum yang tidak dipakai. Adapun hasil langkah ini seperti Tabel 4. Setelah penerapan ekstraksi fitur dengan Regex, proses penggabungan kolom Resep dan Lab dilakukan untuk memudahkan pembobotan dengan TF-IDF. Selain itu, dilakukan juga proses pelabelan pada kolom Kelas_DM menjadi kelas dm-1 dan dm-2.

Berdasarkan hasil konsultasi dan wawancara dengan pakar kesehatan, penentuan dm-1 (diabetes mellitus kelas 1) berdasarkan data pada kolom Resep atau kolom Kelas_DM, di mana jika pasien mendapatkan resep obat yang termasuk insulin (*levemir*, *novorapid*, *novomix*, *humalog mix*, *ryzodeg*, *sansulin*, *ezelin*, *lantus*), atau kode pada kolom Kelas_DM adalah e.10, maka tergolong diabetes mellitus kelas 1 (dm-1). Adapun selain itu, tergolong diabetes mellitus kelas 2 (dm-2). Namun demikian, pada penelitian ini, penentuan kelas diabetes mellitus masih terbatas berdasarkan resep dan kode penyakit. Adapun hasil penggabungan dan pelabelan sebagai berikut, seperti pada Tabel 5. Selanjutnya adalah proses pembobotan dengan TF-IDF. Pembobotan ini dilakukan pada data yang telah terekstraksi fitur dengan Regex, dan data yang tidak terekstraksi fitur.

Langkah berikutnya adalah pembangunan model klasifikasi menggunakan SVM. Sebanyak 80% data dipakai untuk melatih model, dan 20% data digunakan untuk menguji seberapa baik model bekerja. Penelitian ini menggunakan SVM dengan kernel linear, karena SVM kernel linear dapat bekerja dengan mencari garis atau bidang pemisah yang paling tepat agar dua kelompok data dapat terpisah dengan jelas [42]. Metode ini menggunakan pendekatan pembelajaran terawasi dan sangat efektif ketika data berada pada ruang fitur berdimensi tinggi.


Adapun hasil klasifikasi pada data yang terekstraksi fitur dengan Regex adalah pada Gambar 3 berikut.

Classification Report:				
	precision	recall	f1-score	support
dm-1	0.9981	0.9802	0.9890	1059
dm-2	0.9772	0.9978	0.9874	904
accuracy			0.9883	1963
macro avg	0.9877	0.9890	0.9882	1963
weighted avg	0.9885	0.9883	0.9883	1963

Gambar 3. Hasil *classification report* pada SVM menggunakan ekstraksi fitur dengan Regex

Berdasarkan hasil *classification report* pada SVM dengan ekstraksi fitur menggunakan Regex pada Gambar 3 di atas, dapat disimpulkan akurasi model sebesar 0,9883 menunjukkan bahwa sekitar 98,83% sampel berhasil diklasifikasikan dengan benar, sehingga model memiliki kinerja keseluruhan yang sangat baik pada data ini. *Precision* untuk kelas dm-1 sebesar 0,9981 dan dm-2 sebesar 0,9772, dengan rata-rata tertimbang 0,9885, yang berarti proporsi prediksi positif yang benar sangat tinggi, di mana ketika model memprediksi suatu kelas akan menghasilkannya hasil yang hampir selalu benar, sehingga kesalahan *false positive* sangat kecil. *Recall* untuk dm-1 sebesar 0,9802 dan untuk dm-2 sebesar 0,9978, dengan rata-rata makro sekitar 0,9890, yang berarti sebagian besar sampel yang benar-benar termasuk tiap kelas berhasil terdeteksi oleh model, sehingga kesalahan *false negative* juga sangat rendah.

Kemudian *F1-score* dm-1 sebesar 0,9890 dan dm-2 sebesar 0,9874, dengan rata-rata tertimbang 0,9883. Nilai F1 yang sangat tinggi ini menunjukkan keseimbangan yang sangat baik antara *precision* dan *recall*, sehingga model tidak hanya akurat secara keseluruhan tetapi juga stabil dalam menghindari baik *false positive* maupun *false negative*.

Gambar 4. *Confusion matrix* pada SVM menggunakan ekstraksi fitur dengan Regex

Kemudian, dengan melihat hasil *confusion matrix* pada Gambar 4 di atas, dapat disimpulkan bahwa sebanyak 1038 kasus dm-1 dan 902 kasus dm-2 berhasil dikenali dengan label yang tepat oleh model sebagai *True Positive* (TP). Untuk kelas dm-1, *True Negative* (TN) adalah 902, dan untuk kelas dm-2, TN adalah 1038 (semua data dm-1 yang benar diprediksi dm-1), yang berarti, model sangat jarang salah menganggap suatu kelas sebagai kelas lainnya, sehingga pemisahan kedua kelas sangat baik.


False positive (FP) untuk dm-1 adalah 2, yaitu 2 data dm-2 yang salah diklasifikasikan sebagai dm-1. Ini berarti hanya sedikit kasus dm-2 yang salah dikenali menjadi dm-1, sehingga kesalahan pada dm-1 sangat rendah. Sedangkan *False negative* (FN) untuk dm-1 adalah 21, yaitu 21 data dm-1 yang salah diprediksi sebagai dm-2, menunjukkan masih ada sebagian kecil kasus dm-1 yang luput dan dikira dm-2, namun jumlahnya relatif kecil dibanding total data sehingga performa model tetap sangat baik.

Classification Report:				
	precision	recall	f1-score	support
dm-1	1.0000	0.9803	0.9900	1064
dm-2	0.9772	1.0000	0.9885	899
accuracy			0.9893	1963
macro avg	0.9886	0.9901	0.9892	1963
weighted avg	0.9895	0.9893	0.9893	1963

Gambar 5. Hasil *classification report* pada SVM tanpa ekstraksi fitur

Adapun menurut hasil *classification report* pada SVM tanpa ekstraksi fitur pada Gambar 5 di atas, akurasi model sebesar 0,9893 berarti sekitar 98,93% dari total 1963 data diklasifikasikan dengan benar, menunjukkan kinerja keseluruhan yang sangat baik dan kesalahan klasifikasi yang sangat kecil.


Precision kelas dm-1 adalah 1,0000 dan dm-2 adalah 0,9772, dengan rata-rata tertimbang 0,9895. Ini berarti, hampir semua prediksi positif untuk kedua kelas benar, sehingga jumlah *false positive* sangat rendah dan model sangat dipercaya ketika memberikan suatu label kelas. *Recall* dm-1 sebesar 0,9803 dan dm-2 sebesar 1,0000, dengan rata-rata makro 0,9901. Ini menunjukkan bahwa hampir semua sampel yang sebenarnya termasuk tiap kelas berhasil terdeteksi, sehingga jumlah *false negative* juga sangat kecil dan model jarang “meloloskan” kasus yang seharusnya terdeteksi. *F1-score* dm-1 sebesar 0,9900 dan dm-2 sebesar 0,9885, dengan rata-rata tertimbang 0,9893. Nilai F1 yang sangat tinggi ini juga menunjukkan keseimbangan yang sangat baik antara *precision* dan *recall*, sehingga model tidak hanya akurat secara global tetapi juga konsisten dalam mengurangi kedua jenis kesalahan sekaligus.



Gambar 6. *Confusion matrix* pada SVM tanpa ekstraksi fitur

Hasil *confusion matrix* pada SVM tanpa ekstraksi fitur seperti tertampil pada Gambar 6 di atas, menunjukkan *True Positive* (TP) untuk kelas dm-1 sebesar 1043, dan kelas dm-2 sebesar 899. Hal ini berarti sebagian besar sampel di masing-masing kelas berhasil dikenali dengan label yang tepat oleh model. Adapun *True Negative* (TN), pada kelas dm-1 sebesar 899, dan dm-2 sebesar 1043. Ini menunjukkan bahwa model sangat konsisten dalam membedakan mana data yang bukan termasuk suatu kelas tertentu. *False Positive* (FP) untuk dm-1 adalah 0, dan dm-2 adalah 21. Artinya, tidak ada kasus dm-2 yang keliru dianggap dm-1, sedangkan masih ada sedikit kasus dm-1 yang keliru dianggap dm-2. Sedangkan *False Negative* (FN) pada dm-1 adalah 21, dan dm-2 adalah 0. Ini berarti semua kasus dm-2 berhasil terdeteksi, sedangkan terdapat sebagian kecil kasus dm-1 yang lolos dan diklasifikasikan sebagai dm-2, namun jumlahnya relatif kecil dibanding total data.

Berdasarkan Gambar 7, kedua model SVM, baik dengan dan tanpa ekstraksi fitur Regex, menunjukkan kinerja yang sangat tinggi karena akurasi, *precision*, *recall*, dan *F1-score* keduanya berada di kisaran 0,98–0,99 untuk semua metrik. Model dengan ekstraksi fitur Regex memiliki akurasi 0,9883, sedangkan model tanpa ekstraksi fitur sedikit lebih tinggi dengan akurasi 0,9893, sehingga keduanya sama-sama sangat andal dalam mengklasifikasikan data.



Gambar 7. Perbandingan *classification report* pada SVM dengan dan tanpa ekstraksi fitur dengan Regex

Menurut hasil *precision* dan *recall* per kelas, pola keduanya juga sangat mirip. Pada SVM dengan Regex, *precision* dm-1 sedikit di bawah 1 dan dm-2 sedikit di bawah 0,98, sedangkan pada SVM tanpa Regex *precision* dm-1 mencapai 1 penuh dan dm-2 tetap sekitar 0,9772. *Recall* pada model Regex menunjukkan dm-2 sangat tinggi (0,9978), sedangkan pada model tanpa Regex dm-2 bahkan mencapai 1,0000, dengan *recall* dm-1 di kisaran 0,98 pada kedua model. *F1-score* rata-rata kedua model juga hampir sama (0,988–0,989), yang berarti keduanya sama-sama seimbang antara kemampuan menghindari *false positive* dan *false negative*.

4. Kesimpulan

Berdasarkan hasil eksperimen dan evaluasi model yang telah dilakukan, model SVM tanpa ekstraksi fitur sedikit lebih unggul karena memiliki akurasi global lebih tinggi, *precision* dm-1 sempurna (1,0000), *recall* dm-2 sempurna (1,0000), dan *F1-score* rata-rata yang juga sedikit lebih tinggi. Walaupun perbedaannya tipis, SVM tanpa ekstraksi fitur dapat dianggap sebagai model yang performanya paling baik di antara kedua model tersebut. SVM dengan ekstraksi fitur menggunakan Regex lebih rendah, kemungkinan disebabkan karena penggunaan Regex dapat mereduksi atau menyaring pola tertentu dari teks/data, sehingga sebagian karakteristik asli dapat hilang. Jika pola yang dibuang tersebut sebenarnya relevan untuk membedakan dm-1 dan dm-2, maka model dengan Regex justru kehilangan sinyal penting sehingga performanya sedikit turun dibanding memakai fitur asli yang lebih lengkap.

Pada penelitian yang akan datang, dapat dilakukan penerapan *Synthetic Minority Oversampling Technique* (SMOTE) pada sebaran/distribusi data. SMOTE bekerja dengan membuat contoh data baru dari kelas yang jumlahnya sedikit agar distribusi datanya lebih seimbang. Dengan dataset yang lebih proporsional, model mesin dapat belajar dengan lebih adil dan menghasilkan prediksi yang lebih akurat [39]. Selain itu, dapat juga menerapkan validasi yang lebih ketat, seperti *k-fold cross-validation*. Penerapan *k-fold cross-validation* dapat membantu mengurangi bias serta mencegah *overfitting*, dan digunakan untuk menentukan jumlah iterasi validasi yang paling tepat [43].

Ucapan Terimakasih

Penulis mengucapkan terima kasih yang mendalam kepada Direktorat Jenderal Riset dan Pengembangan, Kementerian Pendidikan Tinggi, Sains, dan Teknologi atas dukungan pendanaan melalui Kontrak Pelaksanaan Penelitian dan Pengabdian kepada Masyarakat Tahun 2025 (Nomor: 164/PL43/AL/04/2025).

Daftar Pustaka

- [1] S. Usabili and U. Indahyanti, "Pemodelan Deteksi Dini Diabetes Mellitus menggunakan Pendekatan Ensemble Learning," *Manaj. Pelayanan Kesehat.*, no. 1, pp. 1–12, 2024.
- [2] I. T. Utami, D. Damhudi, and D. Sulistyawati, "SCIENTIFIC JOURNAL OF NURSING RESEARCH," *Sci. J. Nurs. Res.*, no. 46, pp. 13–18, 2019.
- [3] A. Z. Abidin, A. Widhiyanto, and N. Laili, "EFEKTIFITAS SENAM DIABETES MELLITUS DAN TERAPI TERTAWA TERHADAP PENURUNAN GLUKOSA DARAH PASIEN DIABETES MELITUS DI DESA SUMBERWRINGIN," *J. Keperawatan*, pp. 11–19, 2025.
- [4] H. S. Monoarfa, N. A. Djamiluddin, and S. F. M. Arsad, "TINGKAT PENGETAHUAN DAN PERILAKU PERAWATAN KAKI PENDERITA DIABETES MELITUS," vol. 7, no. 1, pp. 90–101, 2025.
- [5] P. Parjono and S. Kusumadewi, "Pemodelan *Text mining* dalam Pengkodean Penyakit Pasien Berdasar Kode ICD 10," vol. 02, pp. 200–207, 2023.
- [6] T. C. Sari, "TEXT MINING UNTUK EKSTRAKSI INFORMASI DARI DOKUMEN," *Duniadata.org*, vol. 1, no. 6, pp. 1–16, 2024.
- [7] G. A. Buntoro, A. D. Wibawa, and M. H. Purnomo, "Text mining in Healthcare for Disease Classification using Machine Learning Algorithm," *Int. Electron. Symp. 2021 Wirel. Technol. Intell. Syst. Better Hum. Lives, IES 2021 - Proc.*, pp. 97–101, 2021, doi: 10.1109/IES53407.2021.9593998.
- [8] I. Hendrickx, T. Voets, P. van Dyk, and R. B. Kool, "Using text mining techniques to identify health care providers with patient safety problems: Exploratory study," *J. Med. Internet Res.*, vol. 23, no. 7, pp. 1–9, 2021, doi: 10.2196/19064.
- [9] C. V. Cosgriff et al., "Developing well-calibrated illness severity scores for decision support in the critically ill," *npj Digit. Med.*, vol. 2, no. 1, 2019, doi: 10.1038/s41746-019-0153-6.
- [10] E. Hassan, T. Abd El-Hafeez, and M. Y. Shams, "Optimizing classification of diseases through language model analysis of symptoms," *Sci. Rep.*, vol. 14, no. 1, pp. 1–24, 2024, doi: 10.1038/s41598-024-51615-5.
- [11] R. Ferreira-da-Silva et al., "Assessing medication use patterns by clinical outcomes severity among inpatients with COVID-19: A retrospective drug utilization study," *Biomed. Pharmacother.*, vol. 172, no. December 2023, 2024, doi: 10.1016/j.biopha.2024.116242.
- [12] S. Das, S. Kumar Mahata, A. Das, and K. Deb, "Disease Prediction from Drug Information using Machine Learning," *Am. J. Electron. Commun.*, vol. 1, no. 4, pp. 16–21, 2021, doi: 10.15864/ajec.1403.
- [13] R. Farizki, N. Supriatna, and C. Juliane, "CLASSIFICATION OF DRUG USAGE PATTERNS AND IDENTIFICATION OF DISEASES IN THE PROVISION OF DRUG TYPES USING THE K-NEAREST NEIGHBORS METHOD," *J. WORLD Sci.*, vol. 3, no. 11, pp. 1554–1564, 2024, doi: 10.58344/jws.v3i11.600.
- [14] D. Lu, H. Wang, R. Yu, H. Yang, and Y. Zhao, "Integrated infection control strategy to minimize nosocomial infection of coronavirus disease 2019 among ENT healthcare workers," *J. Hosp. Infect.*, vol. 104, no. 4, pp. 454–455, 2020, doi: 10.1016/j.jhin.2020.02.018.
- [15] J. Collado-Montañez et al., "Automatic text classification of prostate cancer malignancy scores in radiology reports using NLP models," *Med. Biol. Eng. Comput.*, pp. 3373–3383, 2024, doi: 10.1007/s11517-024-03131-x.
- [16] J. T. Song, J. J. Huang, and R. L. Liu, "Integrating NLP and LLMs to discover biomarkers and mechanisms in Alzheimer's disease," *SLAS Technol.*, vol. 31, no. November 2024, p. 100257, 2025, doi: 10.1016/j.slast.2025.100257.
- [17] M. B. Fernandes et al., "Classification of neurologic outcomes from medical notes using natural language processing," *Expert Syst. Appl.*, vol. 214, no. October 2022, p. 119171, 2023, doi: 10.1016/j.eswa.2022.119171.
- [18] S. Rahman et al., "Attention-Based CNN Model for Burn Severity Assessment," *BHI 2023 - IEEE-EMBS Int. Conf. Biomed. Heal. Informatics, Proc.*, no. M1, pp. 0–3, 2023, doi:

- 10.1109/BHI58575.2023.10313435.
- [19] S. Nazari Nezhad, M. H. Zahedi, and E. Farahani, "Detecting diseases in medical prescriptions using data mining methods," *BioData Min.*, vol. 15, no. 1, pp. 1–20, 2022, doi: 10.1186/s13040-022-00314-w.
 - [20] A. D. H. Musta'in, A. Sanjaya, and A. B. Setiawan, "Penerapan Regular Expression dan Cosine Similarity pada Uji Kemiripan Kalimat Bahasa Indonesia," vol. 9, pp. 154–162.
 - [21] A. I. Gufroni, S. Yuliyanti, and E. N. F. Dewi, "Ekstraksi Fitur menggunakan Regular Expression pada Naïve Bayes Classifier untuk Analisis Sentimen," *MIND (Multimedia Artif. Intell. Netw. Database) J.*, vol. 8, no. 2, pp. 230–241, 2023.
 - [22] N. Arifin, U. Enri, and N. Sulistiyowati, "PENERAPAN ALGORITMA SUPPORT VECTOR MACHINE (SVM) DENGAN TF-IDF N-GRAM UNTUK TEXT CLASSIFICATION," vol. 6, no. 2, 2021.
 - [23] T. P. Lestari, "Analisis *Text mining* pada Sosial Media Twitter Menggunakan Metode Support Vector Machine (SVM) dan Social Network Analysis (SNA)," vol. 4, no. 3, pp. 65–71, 2022, doi: 10.37034/infeb.v4i3.146.
 - [24] A. Farisi, A. Homaidi, and H. Hermanto, "Prediksi Penyakit Diabetes Menggunakan Algoritma Support Vector Machine (SVM)," *J. Teknol. dan Manaj. Ind. Terap.*, vol. 4, no. 3, pp. 612–621, 2025.
 - [25] P. R. Putri and R. Alit, "Klasifikasi Penyakit Diabetes Melitus Menggunakan Metode Support Vector Machine (SVM)," *JINACS J. Informatics Comput. Sci.*, vol. 06, no. Dm, pp. 740–746, 2024.
 - [26] G. Abdurrahman and H. Oktavianto, "JUSTIFY : Jurnal Sistem Informasi Ibrahimy KLASIFIKASI TEKS MINING UNTUK DETEKSI KANKER," *JUSTIFY J. Sist. Inf. Ibrahimy*, vol. 3, no. 1, pp. 16–20, 2024, doi: 10.35316/justify.v3i1.5028.
 - [27] A. Desiani, N. R. Dewi, M. Arhami, D. S. Sitorus, and S. Rahmadita, "PERBANDINGAN ALGORITMA SUPPORT VECTOR MACHINE (SVM) DAN NAÏVE," *Positif J. Sist. dan Teknol. Inf.*, vol. 10, no. 1, pp. 65–74, 2024.
 - [28] R. A. Syahputra and M. R. Hanifah, "Metode Analisis Kesehatan Dengan Menggunakan Machine Learning Atau Artificial Inteligenci Atau Data Mining Literature Review," *J. Invasi Ind. Inov.*, vol. 1, no. 2, pp. 27–38, 2024.
 - [29] M. I. Sodikin and E. Utami, "Pengembangan Machine Learning dalam Preskripsi Obat Pasien untuk Mengurangi Kesalahan Penggunaan Obat dan Mencegah Kerugian Rumah Sakit akibat Pemakaian Obat yang Tidak Tepat," *SUDO J. Tek. Inform.*, no. M1, 2025.
 - [30] C. A. Flores, R. L. Figueroa, J. E. Pezoa, and Q. Zeng-treidler, "CREGEX: A Biomedical Text Classifier Based on Automatically Generated Regular Expressions," *IEEE Access*, vol. 8, 2020.
 - [31] M. Cui, R. Bai, Z. Lu, X. Li, U. Aickelin, and P. Ge, "Regular Expression Based Medical Text Classification Using Constructive Heuristic Approach," *IEEE Access*, vol. 7, pp. 147892–147904, 2019, doi: 10.1109/ACCESS.2019.2946622.
 - [32] J. Pardede and I. Pakpahan, "Analisis Sentimen Penanganan Covid-19 Menggunakan Metode Long Short-Term Memory Pada Media Sosial Twitter," *J. Publ. Tek. Inform.*, vol. 2, no. 1, 2023.
 - [33] S. A. Gani, "Kategorisasi Dan Anotasi Bahan Pembelajaran Menggunakan Pendekatan Kesamaan Teks," *Ind. Eng. J.*, vol. 9, no. 1, p. 45, 2020, doi: 10.53912/iejm.v9i1.501.
 - [34] D. Hu, S. Li, H. Zhang, N. Wu, and X. Lu, "Using Natural Language Processing and Machine Learning to Preoperatively Predict Lymph Node Metastasis for Non-Small Cell Lung Cancer With Electronic Medical Records: Development and Validation Study," *JMIR Med Inf.*, vol. 10, no. 4, p. e35475, 2022, doi: 10.2196/35475.
 - [35] N. Anggraini, E. Surya, N. Harahap, and T. B. Kurniawan, "Text mining - Analisis Teks Terkait Isu Vaksinasi COVID-19 Text mining - Text Analysis Related to COVID-19 Vaccination Issues," *J. IPTEK-KOM (Jurnal Ilmu Pengetah. dan Teknol. Komunikasi)*, vol. 23, no. 2, pp. 141–153, 2021.
 - [36] K. T. Putra, S. Anggraini, L. Sutriani, S. Suradji, and A. Impron, "Analisis Sentimen Masyarakat Kalimantan Tengah Terhadap Perkebunan Kelapa Sawit Menggunakan TF-IDF dan Support Vector Machine," *J. Sci. Mandalika*, vol. 6, no. 5, pp. 1115–1123, 2025.
 - [37] J. J. Sihombing, S. Iskandar, A. Idrus, and D. Y. Niska, "Implementation of text summarization on indonesian scientific articles using textrank algorithm with TF-IDF web-based," pp. 310–319, 2024.
 - [38] L. Afuan, N. Hidayat, and M. Faris, "Sentiment Analysis of the Kampus Merdeka Program on Twitter Using Support Vector Machine and a Feature Extraction Comparison : TF-IDF vs . FastText," vol. 5, no. 4, pp. 1738–1753, 2024.
 - [39] N. W. A. Prasetya, L. P. Wanti, R. Purwanto, I. Bahroni, and R. Listyaningrum, "Evaluasi Kinerja Model Machine Learning dalam Klasifikasi Penyakit THT: Studi Komparatif Naïve Bayes, SVM, dan Random Forest," *Infotekmesin*, vol. 16, no. 02, pp. 312–320, 2025.
 - [40] H. Nalatissifa, W. Gata, S. Diantika, and K. Nisa, "Perbandingan Kinerja Algoritma Klasifikasi Naive Bayes, Support Vector Machine (SVM), dan Random Forest untuk Prediksi Ketidakhadiran di Tempat Kerja," *J. Inform. Univ. Pamulang*, vol. 5, no. 4, p. 578, 2021, doi: 10.32493/informatika.v5i4.7575.
 - [41] S. Suryani and M. Mustakim, "Estimasi Keberhasilan Siswa dalam Pemodelan Data Berbasis Learning Menggunakan Algoritma Support Vector Machine," *Bull. Informatics Data Sci.*, vol. 1, no. 2, p. 81, 2022, doi: 10.61944/bids.v1i2.36.
 - [42] M. A. Ramadhani *et al.*, "IMPLEMENTASI ALGORITMA SUPPORT VECTOR MACHINE (SVM) UNTUK DIAGNOSIS KESEHATAN MANUSIA BERBASIS WEB," *J. Ners*, vol. 9, no. 1, pp. 896–902, 2025.
 - [43] W. Wijiyanto, A. I. Pradana, and V. Atina, "Teknik K-Fold Cross Validation untuk Mengevaluasi Kinerja Mahasiswa," *J. Algoritma*, vol. 21, no. 1, pp. 239–248, 2024, doi: 10.33364/algoritma/v.21-1.1618.